

Uczenie Maszynowe. Laboratorium 2

Modele liniowe: regresja liniowa i logistyczna

Oleksii Furman

Przemysław Dolata

Data aktualizacji: 26.03.2026

1 Cel ćwiczenia

Celem ćwiczenia jest zrozumienie fundamentów uczenia maszynowego poprzez analizę modeli liniowych. W przeciwieństwie do algorytmów „czarnej skrzynki”, modele te oferują wysoką interpretowalność.

Zapoznasz się z problemem **regresji** (przewidywanie wartości ciągłej) oraz **klasyfikacji** (przewidywanie etykiety) w ujęciu geometrycznym. Kluczowym aspektem będzie zbadanie wpływu **regularyzacji** na „złożoność” modelu (bias-variance tradeoff).

Dla studentów chcących zgłębić temat, przygotowano zadanie dodatkowe z **Maszyn Wektorów Nośnych (SVM)**.

2 Wprowadzenie

2.1 Od linii do decyzji

Wiele problemów można sprowadzić do znalezienia optymalnej hiperpłaszczyzny (linii w 2D) w wielowymiarowej przestrzeni cech.

- **Regresja liniowa:** Próbuje dopasować n -wymiarową linię tak, aby zminimalizować błąd (np. sumę kwadratów różnic między predykcją a rzeczywistością).

$$y = w_1x_1 + \dots + w_nx_n + b$$

- **Regresja logistyczna:** Mimo nazwy, jest to klasyfikator. Wynik równania liniowego jest transformowany przez funkcję **sigmoidalną**, co pozwala interpretować wyjście jako prawdopodobieństwo przynależności do klasy.

2.2 Problem przeuczenia i regularyzacja

Gdy model zbyt mocno dopasuje się do danych treningowych (w tym szumu), mamy do czynienia z przeuczeniem (overfitting). Rozwiązaniem jest dodanie kary za „wielkość” wag modelu.

$$\text{Koszt} = \text{Błąd (MSE)} + \alpha \cdot \text{Kara za wielkość wag}$$

- **Ridge (L2):** Preferuje małe, rozproszone wagi.
- **Lasso (L1):** Preferuje wagi zerowe (działa jak automatyczna selekcja cech).

3 Użyte zbiory danych

W ćwiczeniu wykorzystamy zbiory znane z poprzednich laboratoriów:

1. **WINE** (dostępny w sklearn): Tym razem nie będziemy tylko klasyfikować odmian wina. Spróbujemy przewidzieć zawartość konkretnego składnika chemicznego (np. *alcohol* lub *magnesium*) na podstawie pozostałych cech (zadanie regresji).
2. **Polish Companies Bankruptcy** (z Lab 1): Zbiór trudny, niezbalansowany, idealny do testowania regresji logistycznej.

4 Przebieg ćwiczenia

4.1 Zadanie 1: Regresja i regularyzacja (zbiór WINE)

1. Załaduj zbiór WINE. Wybierz jedną z cech ciągłych jako cel (np. *alcohol*), a pozostałe pozostaw jako cechy.
2. Podziel zbiór na treningowy i testowy.
3. Uruchom **regresję liniową**, korzystając z `sklearn.LinearRegression`.
4. Oblicz metryki R^2 oraz MSE (Mean Squared Error) na obu podzbiorach.
5. Zastosuj modele z regularyzacją: **Ridge** i **LASSO**.
 - Sprawdź wpływ parametru α na wyniki.
 - **Eksperyment:** Utwórz wykres, gdzie na osi X będzie wartość α (skala logarytmiczna), a na osi Y wartości współczynników (wag) modelu. Zaobserwuj, jak LASSO „zeruje” mniej istotne cechy, dokonując selekcji zmiennych.
6. Wykorzystaj **walidację krzyżową** do wyznaczenia optymalnej wartości α .
 - Porównaj wynik uzyskany przy ręcznie dobranym α z wynikiem zaproponowanym przez walidację krzyżową.
 - Zastanów się, dlaczego ewaluacja modelu na pojedynczym podziale train/test może dawać niestabilne oszacowanie jakości i jak k -fold CV temu zapobiega.

4.2 Zadanie 2: Klasyfikacja probabilistyczna (zbiór Bankruptcy)

1. Załaduj zbiór danych o bankructwie (wybierz jeden rok, np. `3year.arff`).
2. Uruchom **regresję logistyczną** za pomocą `sklearn.LogisticRegression`.
 - **Uwaga:** Modele liniowe są wrażliwe na skalę danych. Użycie `StandardScaler` jest obowiązkowe!
3. Wyniki przedstaw w postaci macierzy pomyłek (*confusion matrix*) oraz wyliczonych na ich podstawie najistotniejszych metryk (np. precyzja, czułość). Liczy się też umiejętność wyjaśnienia *co znaczą* te metryki!
Zinterpretuj wyniki:
 - Które cechy (wskaźniki finansowe) mają największe dodatnie, a które ujemne wagi? Czy ma to sens ekonomiczny?
 - Jak zmieniają się wartości metryk, gdy zmodyfikujemy próg klasyfikacji?

4. Zbadaj zachowanie modelu przy różnych wartościach parametru regularyzacji C . Porównaj działanie regularyzacji Ridge i LASSO (parametr `l1_ratio`).
Wariant regularyzacji Elastic Net możesz również przebadać, ale wyniki tego podejścia będą sprawdzane wyłącznie wtedy, gdy pochwalisz się dostatecznym zrozumieniem teoretycznym metody.

4.3 Zadanie 3 [Dla chętnych]: Geometria SVM

SVM to algorytm szukający najszerszego „marginesu” między klasami w przestrzeni danych.

1. Uruchom klasyfikator **SVM (Support Vector Machine)**, w `sklearn` nazywany też SVC (od Support Vector Classifier) z jądrem liniowym (`kernel='linear'`) na zbiorze Bankruptcy lub WINE (klasyfikacja).
2. Porównaj go z jądrem RBF (`kernel='rbf'`). Czy nieliniowość (zakrzywienie przestrzeni) poprawia wynik?
3. **Wizualizacja:** Wybierz tylko 2 cechy ze zbioru i narysuj granice decyzyjne (*decision boundaries*) dla SVM.

5 Punktacja

Przy realizacji zadania możesz otrzymać max 8 punktów wedle poniższej tabeli:

Pkt	Zadanie
4	Regresja liniowa: Poprawne przeprowadzenie regresji, obliczenie błędów (MSE, R^2) i wizualizacja zanikania współczynników w LASSO/Ridge (ścieżka regularyzacji).
4	Regresja logistyczna: Poprawne przeprowadzenie procesu (podział danych, skalowanie, uczenie i testowanie modelu), wyliczenie i interpretacja metryk jakości oraz wag modelu (wskazanie najważniejszych cech wpływających na decyzję), badanie parametru regularyzacji.
-	[Opcjonalnie] SVM: Porównanie jądra liniowego i RBF. Analiza wpływu parametru C (koszt) na margines decyzyjny.

6 Pytania pomocnicze

1. Dlaczego skalowanie danych (np. `StandardScaler`) jest krytyczne dla Lasso/Ridge, a mniej ważne dla Drzew Decyzyjnych?
2. Czym różni się minimalizowanie błędu L_1 od L_2 ?
3. Dlaczego w przypadku niezbalansowanego zbioru (Bankruptcy) „surowa” celność (Accuracy) regresji logistycznej może być myląca? Co nam daje analiza progu prawdopodobieństwa?
4. [Do zadania z SVM]: Co oznacza, że punkt jest „wektorem nośnym”?

7 Literatura

1. Linear Models (scikit-learn): https://scikit-learn.org/stable/modules/linear_model.html
2. Regularization (Ridge/Lasso): https://scikit-learn.org/stable/auto_examples/linear_model/plot_ridge_path.html
3. Cichosz P. „Systemy uczące się”, WNT Warszawa (Rozdziały o modelach liniowych).