



Fundusze
Europejskie
Polska Cyfrowa



Rzeczpospolita
Polska

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



AKADEMIA INNOWACYJNYCH ZASTOSOWAŃ TECHNOLOGII CYFROWYCH (AI TECH)

„Uczenie maszynowe” – laboratorium

Laboratorium 3

Klasyfikacja

Indukcja drzew decyzyjnych za pomocą CART

data aktualizacji: 01.04.2026

Cel ćwiczenia

Celem ćwiczenia laboratoryjnego jest zapoznanie się z drzewami decyzyjnymi.

Wprowadzenie

W zadaniu badany będzie algorytm Classification and Regression Trees (CART), aktualnie jedna z najczęściej używanych implementacji. Algorytm działa w oparciu o współczynnik Giniego (mierzący stopień nierównomierności rozkładu, który można w tym kontekście interpretować podobnie jak entropię) i na tej podstawie zachłannie dzieli dane budując finalne drzewo decyzyjne. Algorytm ten ma zestaw hiperparametrów, które mogą krytycznie wpłynąć na skuteczność klasyfikacji wynikowego drzewa decyzyjnego.

Przebieg ćwiczenia

1. Zaczytanie zbiorów danych GLASS **lub** WINE, **oraz** Polish Companies Bankruptcy.

2. Uruchomienie algorytmu drzewa decyzyjnego dla GLASS/WINE dla domyślnych parametrów.
3. Wizualizacja drzewa i analiza jakości klasyfikacji (za pomocą kilku wybranych metryk) wynikowego drzewa decyzyjnego.
4. Wstępne strojenie algorytmów dla zbiorów - sugerowane 3 hiperparametry: `max_depth`, `min_samples_leaf`, `cpp_alpha`, opcjonalnie również `criterion`. W szczególności zwróć uwagę na pruning (`cpp_alpha`).
5. Wizualizacja drzew dla różnych hiperparametrów i analiza jakości klasyfikacji wynikowych drzew decyzyjnych. W raporcie nie wyświetlaj wszystkich drzew – wybierz wyłącznie tych kilka, które pokazują interesujące efekty.
6. Użycie walidacji krzyżowej (zwykłej oraz stratyfikowanej).
7. Użycie parametru wagi klasy (`class_weight`) oraz analiza wyników.
8. Podsumowanie wyników. To jest miejsce na tabelki, wykresy, wnioski – wybieramy prezentowane dane/zestawienia, nie dajemy wszystkich wyników.

Uwaga! Przy tym zadaniu nie używamy *boostingu* – ten mechanizm będzie badany przy okazji jednego z następnych zadań laboratoryjnych.

Punktacja

Za realizację zadania możesz otrzymać **max 10 punktów** według poniższej tabeli:

2	Wczytanie danych, uruchomienie klasyfikatora, wizualizacja wyników.
4	Strojenie hiperparametrów drzewa decyzyjnego oraz zbadanie wpływu na skuteczność. Wizualizacja kilku wybranych wynikowych drzew. (“Jak różnią się wynikowe drzewa pod wpływem różnych zestawów hiperparametrów?”)
2	Zbadanie, jak wyniki uzyskane przy użyciu walidacji stratyfikowanej różnią się od „zwykłej” walidacji krzyżowej.
2	Zbadanie wpływu parametru wagi klasy na wyniki modelu (tylko zbiór PCB).

Przy realizacji tego zadania wystarczy notebook Jupyter. Przy wynikach badań należy dać krótkie komentarze.

Pytania pomocnicze

1. Co znajduje się w liściach drzewa?
2. Czy przycinanie drzewa (*pruning*) jest potrzebne? Na czym polega ten proces?
3. Czy drzewo może być za „duże” lub za „małe”? Co to znaczy?
4. Czy drzewo decyzyjne potrzebuje normalizacji/standaryzacji/dyskretyzacji danych? Dlaczego?
5. Czy model można przeuczyć? Czym się to objawia?
6. Na czym polega wagowanie klas?

Literatura

1. Wykłady do przedmiotu autorstwa prof. H. Kwaśnickiej
2. Cichosz P. "Systemy uczące się", WNT Warszawa
3. Zasoby Internetu: uczenie maszynowe (machine learning), data mining, klasyfikacja, drzewa decyzyjne, indukcja drzew decyzyjnych, pruning (przycinanie drzewa), generalizacja
4. [1.10. Decision Trees — scikit-learn 1.2.2 documentation](#)
5. [sklearn.tree.DecisionTreeClassifier — scikit-learn 1.2.2 documentation](#)
6. [Decision tree learning - Wikipedia](#)