

Laboratorium Uczenia Maszynowego

Zespoły klasyfikatorów

Katarzyna Fojcik, Przemysław Dolata, Bartosz Perz

19.05.2026

Temat

Wykrywanie anomalii i przewidywanie decyzji w danych społecznych i behawioralnych za pomocą zespołów klasyfikatorów.

Cel ćwiczenia

Celem ćwiczenia laboratoryjnego jest zapoznanie się z najpopularniejszymi metodami wykorzystywanymi do rozwiązywania rzeczywistych problemów - zespołami klasyfikatorów (opartymi o drzewa). W szczególności celem zadania będzie przebadanie modeli takich jak Random Forest [1], AdaBoost [2], Histogram-based Gradient Boosting [3], XGBoost [5], LightGBM[6], CatBoost[7].

Wyobraź sobie, że jesteś członkiem zespołu *data-forensics* analizującego zachowania ludzi, ryzyko decyzji lub nietypowe przypadki. Celem tego laboratorium nie będzie jedynie porównanie algorytmów, ale **zrozumienie działania zespołowych modeli drzewiastych w sytuacjach nietrywialnych**, takich jak np.:

- przewidywanie przestępstw w mieście,
- wykrywanie nadużyć w systemach społecznych,
- klasyfikowanie zachowań kierowców, klientów, pacjentów.

Wprowadzenie

Algorytmy oparte o zespoły klasyfikatorów do dnia dzisiejszego są uznawane za state-of-the-art w przypadku problemów na danych tabelarycznych (patrz [8]). Zazwyczaj są one de-facto standardem w praktycznych zastosowaniach w przemyśle i dzięki wielu ich własnościom umożliwiają modelowanie różnorodnych problemów. Przykładami takich własności są: natywne wsparcie dla zmiennych kategorycznych, natywne wsparcie dla brakujących danych, wsparcie dla wag, ograniczenia monotoniczności, ograniczenia interakcji, własne funkcje straty, modelowanie probabilistyczne dla zmiennych ciągłych i wiele innych. Więcej przeczytasz np. w przewodniku użytkownika `scikit-learn` [1,2,3].

Struktura ćwiczenia

1 Wybór zespołu klasyfikatorów i pierwsze uruchomienie

W ramach ćwiczenia przebadasz trzy zespoły klasyfikatorów. Obowiązkowo będą to **Random Forest** [1] i **AdaBoost** [2], a ponadto wybierzesz jeden z następujących zaawansowanych algorytmów: Histogram-based Gradient Boosting [3], XGBoost [5], LightGBM [6], CatBoost [7]. Zapoznaj się z nimi pobieżnie, następnie wybierz jeden, który zgłębisz w większym szczególe.

Pierwszą częścią zadania jest uruchomienie trzech algorytmów zespołowych (bez szukania hiperparametrów) na zbiorze danych GLASS w celu weryfikacji poprawności działania oraz porównania wyników z uzyskanymi w poprzednich listach. W raporcie załącz przykładowe wyniki i porównania.

2 Zadanie: znajdź sprawcę (czyli anomalię lub ryzyko)

Wybierz jeden z niestandardowych zbiorów danych i **określ problem klasyfikacyjny**. Pamiętaj, by mądrze dobrać metryki, za których pomocą będziesz ewaluować badane algorytmy. Dokonaj również odpowiedniej eksploracji danych przed przystąpieniem do zadania (tej części zadania nie musisz raportować tak drobiazgowo w jak w poprzednich listach, zilustruj jedynie cechy wyróżniające wybrany zbiór).

Twoim celem będzie rozwiązanie jednego z dwóch problemów (w zależności od danych):

- **Wykrywanie nietypowych przypadków (anomalii)** – np. rzadkie oszustwa lub odstępstwa od normy,
- **Przewidywanie działania** – np. czy ktoś popełni przestępstwo, wróci do szpitala, opuści usługę (churn).

Przykładowe zbiory danych:

- COMPAS: przewidywanie recydywy
<https://github.com/propublica/compas-analysis>
- NYC 311 Complaints: analiza zgłoszeń obywatelskich
<https://opendata.cityofnewyork.us/>
- Hospital Readmissions
<https://archive.ics.uci.edu/ml/datasets/diabetes+130-us+hospitals+for+years+1999-2008>
- Driving Behavior
<https://www.kaggle.com/datasets/shashwatwork/driving-behavior-dataset>
- Human Rights Violations
<https://hrdag.org/data-publication/>

3 Hiperparametry zespołów klasyfikatorów

Zapoznaj się z hiperparametrami dostępnymi dla wybranych klasyfikatorów zespołowych. Na podstawie wiedzy teoretycznej i dokumentacji, wybierz dla każdego klasyfikatora 2-3 najistotniejsze hiperparametry. Następnie przeanalizuj ich wpływ na wybrane metryki jakości predykcji, opierając swoje obserwacje o konkretne wyniki i wykresy.

4 Analiza działania zespołów klasyfikatorów

Porównaj wybrane algorytmy pod kątem skuteczności, zrozumiałości i sprawiedliwości. W porównaniach możesz ograniczyć się do najlepszych konfiguracji modeli zidentyfikowanych w poprzednim zadaniu.

Skuteczność musisz zdefiniować własnoręcznie w zależności od wybranego zbioru danych. Opis zbioru często sugeruje albo narzuca metryki, których należy używać w danym zadaniu - zapoznaj się z nim i postępuj odpowiednio.

Zrozumiałość oznacza możliwość wyjaśnienia, dlaczego model podjął daną decyzję. Umożliwiają one ocenę wpływu poszczególnych cech na wynik predykcji. Przykładowe techniki interpretacji to *feature importance*, *SHAP*, *LIME*, *PDP* (wybierz jedną).

Sprawiedliwość (*fairness*) dotyczy tego, czy model podejmuje decyzje bez uprzedzeń (np. względem określonych grup społecznych). Modele mogą niezamierzenie reprodukcować bias obecny w danych historycznych. Techniki badania fairness to np. *demographic parity*, *equal opportunity*, biblioteka *Fairlearn* (wybierz jedną).

5 Eksperyment socjotechniczny: co jeśli...?

Zmień jeden czynnik będący potencjalnym źródłem uprzedzeń modelu (np. płeć, wiek - zależnie od wybranego zbioru danych i zadania) i sprawdź, jak zmieniają się wyniki predykcji. Czy model jest podatny na bias?

6 * Funkcjonalności zespołów klasyfikatorów

Zadanie dla chętnych. Wybrany przez Ciebie zaawansowany klasyfikator zespołowy najprawdopodobniej wspiera którąś z następujących funkcjonalności: ograniczenia monotoniczności, ograniczenia interakcji, własne funkcje straty lub inne. Przeprowadź eksperyment sprawdzający wpływ (jednej) wybranej funkcjonalności na wyniki oraz zachowanie modelu.

7 Mini raport śledczy

Kródko podsumuj wyniki badań:

- Co było najważniejsze w predykcji?
- Czy model działa sprawiedliwie?
- Co należy zmienić, by model mógł być używany w praktyce?

Punktacja

Przy realizacji zadania możesz otrzymać **max 8 punktów** wedle poniższej punktacji:

1	Wybór i uruchomienie algorytmów na prostym zbiorze (sanity check)
1	Analiza eksploracyjna wybranego niestandardowego zbioru danych
3	Badanie wpływu hiperparametrów na działanie algorytmów
3	Analiza działania zespołów klasyfikatorów na wybranym zadaniu
	Badanie wybranej funkcjonalności zespołu klasyfikatorów

Literatura

1. RandomForest - <https://scikit-learn.org/stable/modules/ensemble.html#random-forest>
2. Adaboost - <https://scikit-learn.org/stable/modules/ensemble.html#adaboost>
3. HistGradientBoosting - <https://scikit-learn.org/stable/modules/ensemble.html#histogram-based-gradient-boosting>
4. Introduction to Boosted Trees - <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>
5. XGBoost - <https://xgboost.readthedocs.io/en/stable/>
6. LightGBM - <https://lightgbm.readthedocs.io/en/stable/>
7. CatBoost - <https://catboost.ai/>
8. Why do tree-based models still outperform deep learning on tabular data? - <https://arxiv.org/pdf/2207.08815>